我们先训练了一个分辨雾浓度的模型

数据怎么处理

读取透射率 PNG，从文件名取得 β 标签
转灰度 → 缩放至 64×32 → 除以 255
分成淡雾、中雾、浓雾三个等级

模型：3 层卷积，通道 1→8→16→24
训练：交叉熵 + AdamW，共 5 轮

原代码中用到的库

PyTorch：建模型、训练、保存权重
NumPy：把图片转成数值数组
Pillow：读取、转灰度和缩放图片

```
from PIL import Image
import numpy as np
import torch
from torch import nn
```

$t = \exp(-\beta d)$：d 是距离，β 越大衰减越强。原模型接收的是透射率图。

依据：报告第 5 页；训练、识别脚本。

训练后，我们检查它到底判对了多少

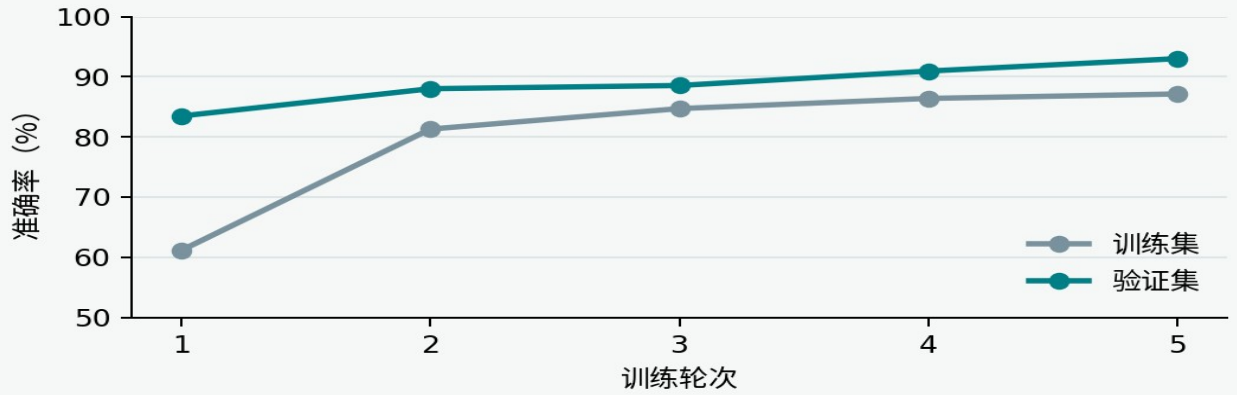
92.46% 测试准确率： 4,230 / 4,575

0.9248 综合分类得分（Macro F1）

每格为图片数：行是真实等级，列是判断

	淡雾	中雾	浓雾
淡雾	1370	155	0
中雾	94	1384	47
浓雾	0	49	1476

验证准确率： 83.47% → 93.00%



测试损失 0.23637； 49 张浓雾被判成中雾。 92.46% 是合成透射率图上的成绩。

依据：报告第 5、 8–9 页； metrics.json、 training_history.csv。

对真实雾图，我们另外记录了五个特征

特征	我们记录什么	雾越重时的评分方向
亮度	整体平均亮度	越大 → 越严重
对比度	物体和背景能否分开	越小 → 越严重
饱和度	颜色是否还鲜明	越小 → 越严重
暗通道	局部区域最暗颜色通道的统计量	越大 → 越严重
边缘密度	可见边缘像素占全部像素的比例	越小 → 越严重

先统一量级： Z = （当前值 − 全部图片的均值） / 标准差，再做综合评分。

这里用了 100 张真实图；方向是评分模型的约定，光照与场景变化也会影响这些数值。

依据：报告第 6 、 14 页； 100 张图片的记录见附录 B 。

接着，把模型输出和特征评分放到同一尺度

① 不只取最高概率，而是保留三个等级的概率

$$\beta_{图像} = 0.005\,P_{淡} + 0.010\,P_{中} + 0.020\,P_{浓} \quad (m^{-1})$$

② 把特征评分 C 映射成原报告中的代理 β

$$\beta_{评分} = 3.912 + 74.328\,C \quad (km^{-1};\ C \text{ 在 } 0 \sim 1 \text{ 之间})$$

③ 先把单位统一，再按权重相加

$$\beta_{综合} = \lambda \times (1{,}000\,\beta_{图像}) + (1-\lambda) \times \beta_{评分}$$

P 是各等级概率，λ 决定两边的比重；两种能见度约定仍需统一，λ 还没用真实道路数据拟合。

依据：报告第 5、7、14 页。

然后，用前三个值预测下一个值

输入 $x_t = [\beta_{t-1}, \beta_{t-2}, \beta_{t-3}]$ → 目标：下一次观测的 β_t

随机森林

多棵树分别预测，最后取平均。

XGBoost

逐步增加树，让已有预测的误差变小。

同一组 100 个观测：前 80 个训练，后 20 个测试；不随机打乱。

随机种子 42；比较平均误差、较大误差和变浓／变淡的判断方向。

图像顺序尚未确认对应真实连续时间，因此这里预测的是下一个观测，不能直接换算成分钟。

依据：报告第 7、11、17 页；预测设置按报告整理。

这次预测比较， ARIMA 的误差最小

模型	平均误差 MAE	RMSE	R^2	方向判断准确率
ARIMA(0,1,1)	16.3759	19.5360	−0.0554	70.0%
随机森林	17.3133	21.9277	−0.3296	70.0%
XGBoost	17.5265	22.5801	−0.4099	70.0%

MAE 、 RMSE 越小越好，单位为 km^{-1} ； 三种模型用了同一批测试目标。

R^2 都为负：目前的数值预测还不理想，需要连续视频和实测能见度继续验证。

依据：报告第 11 页表 7 ；均为代理 β 的测试结果。